Michał Szczurek lab 6 In [1]: **from collections import** deque import numpy as np import cv2 import matplotlib.pyplot as plt import time from timeit import timeit import random, string 1. Zaimplementuj algorytm wyszukiwania wzorca 2-wymiarowego In [2]: class Node: def \_\_init\_\_(self, char, parent, node\_id, accepting): self.children = {} self.accepting = accepting self.char = char self.id = node\_id self.parent = parent self.fail\_link = None def add\_child(self, char): d[char] = Node(char) def has\_child(self, char): return char in self.children def \_\_str\_\_(self): return str(self.char) + " " + str(self.id) + " " + str(self.accepting) In [3]: class Automaton: def \_\_init\_\_(self, patterns): self.root = Node("\$", None, 0, None) self.next\_id = 1 self.pattern\_dict = {} # to store patterns ids self.patterns = patterns for i, p in enumerate(patterns): self.add(i, p) self.add\_fail\_links() self.transform() def add(self, index, text): i = 0 node = self.root while i < len(text) and node.has\_child(text[i]):</pre> node = node.children[text[i]] i += 1 while i < len(text):</pre> node.children[text[i]] = Node(text[i], node, self.next\_id, index if i == len(text) - 1 else None) **if** i == len(text) - 1: self.pattern\_dict[text] = index node = node.children[text[i]] i += 1 self.next\_id +=1 def add\_fail\_links(self): que = deque() for (key, node) in self.root.children.items(): que.append(node) # first level fail links while len(que) > 0: curr = que.popleft() if curr.parent is not self.root: for node in curr.children.values(): que.append(node) curr.fail\_link = self.root else: # while's else - Trie has only 1 level curr = **None** # other fail links while curr: # add children for later for node in curr.children.values(): que.append(node) # build fail link char = curr.charprev = curr.parent.fail\_link while char not in prev.children and prev is not self.root: prev = prev.fail\_link # "joker" from root case if prev is self.root and char not in self.root.children: curr.fail\_link = self.root else: curr.fail\_link = prev.children[char] if len(que) > 0: curr = que.popleft() else: curr = None def transform(self): """Takes tree with fail links and returns tree with 'shortcut' edges""" que = deque() for node in self.root.children.values(): que.append(node) while len(que) > 0: curr = que.popleft() for node in curr.children.values(): que.append(node) for char, child in curr.fail\_link.children.items(): if char not in curr.children: curr.children[char] = child def search(self, text): res = [-1 **for** \_ **in** text] state = self.root for i, char in enumerate(text): if char not in state.children: state = self.root else: state = state.children[char] if state.accepting != None: res[i] = state.accepting **return** res In [4]: def search\_2d(text, patterns): """Returns coordinates of lower right symbol of pattern""" pattern\_set = set(patterns) automaton\_1d = Automaton(pattern\_set) res\_1d = [automaton\_1d.search(line) for line in text] res\_1d = np.array(res\_1d).transpose() pattern = tuple([automaton\_1d.pattern\_dict[p] for p in patterns]) # pattern made of patterns using ids automaton\_2d = Automaton([pattern]) res\_2d = [automaton\_2d.search(line) for line in res\_1d] res = []for i in range(len(res\_2d)): for j in range(len(res\_2d[i])): **if** res\_2d[i][j] != -1: res.append((j, i)) return res 2. Znajdź w załączonym pliku "haystack.txt" wszyskie sytuacje, gdy taka sama litera występuje na tej samej pozycji w dwóch kolejnych linijkach. Zwróć uwagę, na nierówną długość linii w pliku. Funkcja dodająca do tekstu meta-znaki, tak by tekst był prostokątny In [5]: def parse\_text(text, null\_symbol='\$'):  $max_len = 0$ for 1 in text:  $max_len = max(max_len, len(1))$ res = []for line in text: res.append(line + str((max\_len - len(line)) \* null\_symbol)) In [6]: with open("haystack.txt", 'r', encoding='utf-8') as file: text = file.readlines() Wyszukanie sytuacji z polecenia In [7]: letters = set() for line in text: for c in line: letters.add(c) total = 0 letters = sorted(letters) **for** letter **in** letters: res = search\_2d(parse\_text(text), [letter, letter]) print(f"{repr(letter)} Liczba sytuacji: {len(res)} : {res}") total += len(res) print(f"W sumie {total} sytuacji") '\n' Liczba sytuacji: 1 : [(36, 79)] ' 'Liczba sytuacji: 158 : [(28, 1), (38, 1), (63, 1), (2, 2), (3, 2), (60, 2), (61, 2), (20, 3), (21, 3), (28, 3), (29, 3), (38, 3), (28, 5), (38, 5), (5, 7), (6, 7), (11, 7), (38, 7), (39, 7), (58, 7), (25, 8), (34, 8), (41, 8), (5, 7), (6, 8), (6, 9), (1, 10), (2, 10), (53, 10), (11, 11), (16, 11), (21, 11), (47, 12), (58, 12), (23, 13), (45, 13), (64, 13), (60, 14), (32, 15), (33, 15), (41, 15), (42, 15), (62, 15), (25, 16), (69, 16), (70, 16), (33, 17), (61, 18), (3 3, 19), (23, 20), (24, 20), (25, 20), (46, 20), (59, 20), (52, 21), (57, 21), (23, 22), (81, 22), (31, 23), (48, 23), (49, 23), (24, 24), (25, 24), (77, 24), (9, 25), (38, 26), (48, 26), (71, 26), (80, 26), (1, 27), (82, 27), (31, 29),(54, 29), (57, 29), (63, 29), (80, 29), (23, 30), (64, 31), (19, 32), (46, 32), (47, 32), (55, 32), (72, 32), (36, 32)3), (42, 33), (43, 33), (58, 33), (2, 34), (55, 34), (44, 35), (45, 35), (49, 35), (55, 36), (24, 38), (21, 39), (72, 40), (4, 41), (23, 42), (57, 42), (59, 43), (4, 44), (25, 44), (34, 44), (69, 44), (6, 45), (7, 45), (41, 46), (55, 4 6), (79, 46), (10, 48), (61, 48), (64, 48), (22, 49), (82, 50), (21, 51), (22, 51), (31, 51), (63, 51), (60, 52), (6 1, 52), (32, 55), (49, 55), (31, 57), (64, 57), (1, 58), (15, 58), (16, 58), (24, 58), (47, 58), (22, 59), (49, 59), (71, 59), (14, 60), (24, 60), (61, 60), (62, 60), (63, 60), (45, 61), (42, 62), (54, 62), (70, 62), (71, 62), (25, 62)3), (38, 63), (81, 63), (5, 64), (36, 64), (29, 66), (59, 67), (43, 68), (22, 69), (35, 69), (41, 69), (33, 72), (1, 73), (47, 75), (21, 76), (61, 76), (23, 77)] '"' Liczba sytuacji: 0 : [] '(' Liczba sytuacji: 0 : [] ')' Liczba sytuacji: 0 : [] ',' Liczba sytuacji: 0 : [] '-' Liczba sytuacji: 0 : [] '.' Liczba sytuacji: 0 : [] '0' Liczba sytuacji: 0 : [] '1' Liczba sytuacji: 0 : [] '3' Liczba sytuacji: 0 : [] '5' Liczba sytuacji: 0 : [] '6' Liczba sytuacji: 0 : [] '7' Liczba sytuacji: 0 : [] ':' Liczba sytuacji: 0 : [] ';' Liczba sytuacji: 0 : [] 'A' Liczba sytuacji: 0 : [] 'B' Liczba sytuacji: 0 : [] 'C' Liczba sytuacji: 0 : [] 'D' Liczba sytuacji: 0 : [] 'E' Liczba sytuacji: 0 : [] 'F' Liczba sytuacji: 0 : [] 'G' Liczba sytuacji: 0 : [] 'I' Liczba sytuacji: 0 : [] 'L' Liczba sytuacji: 0 : [] 'M' Liczba sytuacji: 0 : [] 'N' Liczba sytuacji: 0 : [] '0' Liczba sytuacji: 0 : [] 'P' Liczba sytuacji: 0 : [] 'Q' Liczba sytuacji: 0 : [] 'R' Liczba sytuacji: 0 : [] 'S' Liczba sytuacji: 0 : [] 'T' Liczba sytuacji: 0 : [] 'U' Liczba sytuacji: 0 : [] 'V' Liczba sytuacji: 0 : [] 'W' Liczba sytuacji: 0 : [] 'X' Liczba sytuacji: 0 : [] 'a' Liczba sytuacji: 28 : [(65, 2), (38, 4), (21, 6), (57, 11), (53, 12), (54, 12), (65, 14), (77, 21), (65, 22), (6 0, 24), (4, 30), (66, 35), (70, 35), (58, 36), (59, 36), (80, 37), (78, 42), (54, 48), (32, 50), (79, 59), (6, 60), (78, 61), (7, 63), (34, 66), (29, 69), (32, 73), (77, 74), (1, 82)'b' Liczba sytuacji: 0 : [] 'c' Liczba sytuacji: 6 : [(42, 0), (69, 0), (14, 10), (83, 41), (11, 45), (4, 54)] 'd' Liczba sytuacji: 1 : [(38, 19)] 'e' Liczba sytuacji: 48 : [(11, 1), (15, 2), (25, 3), (18, 6), (77, 6), (78, 6), (81, 6), (2, 8), (21, 10), (41, 11), (82, 14), (70, 15), (68, 17), (73, 23), (41, 26), (19, 27), (74, 27), (52, 31), (43, 36), (30, 38), (72, 38), (16, 4)3), (30, 43), (69, 46), (83, 47), (38, 48), (43, 48), (71, 49), (48, 50), (59, 50), (47, 52), (23, 53), (58, 54), (5 9, 54), (42, 57), (22, 61), (1, 63), (11, 64), (8, 65), (25, 65), (79, 65), (64, 66), (29, 67), (66, 69), (67, 72), (29, 73), (60, 73), (5, 77)] 'f' Liczba sytuacji: 2 : [(78, 1), (31, 59)] 'g' Liczba sytuacji: 0 : [] 'h' Liczba sytuacji: 4 : [(28, 2), (38, 2), (74, 12), (57, 31)] 'i' Liczba sytuacji: 13 : [(32, 0), (2, 5), (74, 13), (78, 13), (56, 17), (32, 31), (45, 33), (9, 37), (61, 45), (69, 51), (20, 55), (10, 60), (53, 69)] 'j' Liczba sytuacji: 0 : [] 'k' Liczba sytuacji: 0 : [] 'l' Liczba sytuacji: 5 : [(34, 45), (54, 45), (47, 61), (29, 72), (42, 77)] 'm' Liczba sytuacji: 5 : [(45, 0), (17, 5), (35, 40), (35, 60), (29, 70)] 'n' Liczba sytuacji: 15 : [(32, 1), (2, 9), (57, 13), (36, 18), (65, 29), (52, 32), (55, 33), (68, 35), (20, 37), (6 8, 40), (15, 54), (21, 56), (68, 57), (22, 62), (1, 83)] 'o' Liczba sytuacji: 21 : [(42, 1), (54, 1), (51, 2), (53, 8), (80, 10), (34, 11), (28, 17), (29, 17), (34, 26), (11, 27), (33, 34), (7, 38), (8, 38), (72, 42), (59, 45), (82, 52), (45, 55), (31, 58), (16, 60), (6, 66), (5, 75)] 'p' Liczba sytuacji: 2 : [(42, 18), (29, 71)] 'q' Liczba sytuacji: 0 : [] 'r' Liczba sytuacji: 21 : [(2, 4), (53, 5), (34, 10), (8, 13), (18, 14), (16, 18), (70, 22), (44, 25), (68, 29), (61, 30), (34, 37), (48, 37), (7, 39), (63, 39), (56, 40), (47, 42), (7, 50), (20, 54), (21, 54), (29, 65), (32, 70)] 's' Liczba sytuacji: 19 : [(55, 0), (50, 14), (9, 21), (72, 24), (80, 24), (38, 34), (46, 34), (68, 37), (71, 41), (4 7, 44), (29, 45), (5, 49), (53, 53), (30, 56), (31, 56), (4, 57), (10, 58), (4, 63), (41, 63)] 't' Liczba sytuacji: 41 : [(38, 0), (51, 0), (17, 3), (72, 3), (73, 3), (24, 4), (25, 4), (70, 5), (2, 6), (1, 7), (2, 7), (23, 8), (36, 10), (73, 10), (55, 11), (16, 12), (5, 14), (31, 16), (78, 22), (5, 23), (29, 23), (47, 24),(8, 29), (28, 31), (20, 33), (52, 33), (60, 33), (4, 37), (42, 45), (59, 49), (29, 52), (56, 54), (14, 55), (62, 56),(73, 59), (53, 61), (68, 71), (42, 73), (9, 75), (60, 75), (59, 78)'u' Liczba sytuacji: 0 : [] 'v' Liczba sytuacji: 0 : [] 'w' Liczba sytuacji: 2 : [(2, 3), (22, 70)] 'x' Liczba sytuacji: 1 : [(29, 68)] 'y' Liczba sytuacji: 1 : [(45, 5)] 'z' Liczba sytuacji: 0 : [] W sumie 394 sytuacji 3. Znajdź wszystkie wystąpienia "th" oraz "t h" w dwóch kolejnych liniach na tej samej pozycji. In [8]: | search\_2d(parse\_text(text), ['th', 'th']) Out[8]: [] In [9]: | search\_2d(parse\_text(text), ['t h', 't h']) Out[9]: [(38, 2)] 4. Wybierz przynajmniej 3 litery (małe). Znajdź wszystkie wystąpienia tej litery w załączonym pliku "haystack.png" Główna funkcja realizująca polecenie In [10]: def search\_image(letter\_img, source\_img, print\_positions=False): # We want immutable type to use dicts later on letter = [] for line in letter\_img: letter.append(tuple(line)) res = search\_2d(source\_img, letter) if print\_positions: print(f"Znaleziono {len(res)} dopasowań na pozycjach {res}") print(f"Znaleziono {len(res)} dopasowań") Funkcja wyszukująca wzorzec zw tekście (.txt) weryfikująca poprawność wyszukiwania obrazów In [11]: def get\_pattern\_count(text, pattern): res = len(search\_2d(text, [pattern])) print("Całkowita liczba dopasowań:", res ) Wczytanie obrazu In [12]: source\_img = cv2.imread("haystack.png", cv2.IMREAD\_GRAYSCALE) plt.imshow(source\_img , cmap='gray') plt.show() 250 500 750 1000 1250 1500 1750 500 Realizacja polecenia In [13]: pattern\_a = source\_img[37:47,263:272] plt.imshow(pattern\_a , cmap='gray') plt.show() In [14]: | search\_image(pattern\_a, source\_img) Znaleziono 397 dopasowań In [15]: | get\_pattern\_count(text, 'a') Całkowita liczba dopasowań: 397 In [16]: pattern\_c = source\_img[213:223,165:173] plt.imshow(pattern\_c , cmap='gray') plt.show() 4 In [17]: | search\_image(pattern\_c, source\_img) Znaleziono 213 dopasowań In [18]: | get\_pattern\_count(text, 'c') Całkowita liczba dopasowań: 213 In [19]: pattern\_m = source\_img[257:267,133:148] plt.imshow(pattern\_m , cmap='gray') plt.show() 2 · 4 10 0 2 6 8 In [20]: | search\_image(pattern\_m, source\_img) Znaleziono 131 dopasowań In [21]: get\_pattern\_count(text, 'm') Całkowita liczba dopasowań: 131 5. Znajdź wszystkie wystąpienia słowa "p a t t e r n" w haystack.png. In [22]: pattern\_long = source\_img[474:491,184:283] plt.imshow(pattern\_long , cmap='gray') plt.show() In [23]: search\_image(pattern\_long, source\_img) Znaleziono 5 dopasowań In [24]: get\_pattern\_count(text, 'p a t t e r n') Całkowita liczba dopasowań: 5 6. Porównaj czas budowania automatu i czas wyszukiwania dla różnych rozmiarów wzorca In [25]: def measure\_time(text, start=5, stop=100, step=5): create\_times = [] search\_times = [] lens = [i for i in range(start, stop + step, step)] **for** i **in** lens: pattern = ''.join(random.choice(string.ascii\_lowercase + string.ascii\_uppercase) for \_ in range(i)) automaton = Automaton([pattern]) create = lambda: Automaton(pattern) search = lambda: automaton.search(text) create\_times.append(timeit(create, number = 5000)) search\_times.append(timeit(search, number = 5000)) plt.plot(lens, create\_times, label="Czas budowania automatu (\*5000)") plt.plot(lens, search\_times, label="Czas wyszukiwania wzorca (\*5000)") plt.title("Porównanie czasu budowania automatu i wyszukiwania wzorca") plt.legend() plt.show() In [29]: measure\_time(text) Porównanie czasu budowania automatu i wyszukiwania wzorca Czas budowania automatu (\*5000) 2.5 Czas wyszukiwania wzorca (\*5000) 2.0 1.5 1.0 0.5 0.0 Test polegał na pomiarze czasu budowy i dopasowania wzorca dla wzorców o długości od 5 do 100 z krokiem 5. Wyniki wskazują na to, że całkowity czas wykonywania się algorytmu jest zdominowany przez czas potrzebny na zbudowanie automatu. 7. Podziel plik na 2, 4 i 8 fragmentów (w poziomie) i porównaj czas przeszukiwania In [34]: def measure\_diffrent\_files(file, pattern='1234567890qwertyuiopasdfghjklzxcvbnm', to\_test = None): times = [] automaton = Automaton([pattern]) if to\_test is None:  $to_{test} = [1, 2, 4, 8]$ for i in to\_test: texts = [] with open(file, 'r', encoding='utf-8') as source: for j in range(i): texts.append([]) **if** j == i - 1: while True: line = source.readline() if not line: break texts[-1].append(line) else: for k in range(len(text) // i): line = source.readline() texts[-1].append(line) test\_times = [] for t in texts:

search = lambda: automaton.search(t)

times.append(test\_times)

for i, test in enumerate(to\_test):

In [37]: measure\_diffrent\_files("haystack.txt")

Wyniki po podziale pliku na 1 części

Sumaryczny czas : 0.542590699998982

Wyniki po podziale pliku na 2 części

Sumaryczny czas : 0.5655957999988459

Wyniki po podziale pliku na 4 części

Sumaryczny czas : 0.6138847000001988

Wyniki po podziale pliku na 8 części

Sumaryczny czas : 0.734222499999305

for j, t in enumerate(times[i]):

\*\*\* Podane czasy odpowiadają 50000 wyszukiwań \*\*\*

Czas dla wyszukania w części 1.: 0.542590699998982

Czas dla wyszukania w części 1.: 0.2822813999991922 Czas dla wyszukania w części 2.: 0.2833143999996537

Czas dla wyszukania w części 1.: 0.15337240000008023 Czas dla wyszukania w części 2.: 0.1553607000005286 Czas dla wyszukania w części 3.: 0.15527750000001106 Czas dla wyszukania w części 4.: 0.1498740999995789

Czas dla wyszukania w części 1.: 0.08549000000130036 Czas dla wyszukania w części 2.: 0.08841799999936484 Czas dla wyszukania w części 3.: 0.08458190000055765 Czas dla wyszukania w części 4.: 0.08358090000001539 Czas dla wyszukania w części 5.: 0.08257629999934579 Czas dla wyszukania w części 6.: 0.08306099999936123 Czas dla wyszukania w części 7.: 0.12016179999955057 Czas dla wyszukania w części 8.: 0.10635259999980917

Wyniki wskazują na to, że dzielenie tekstu na fragmenty, pogorszyło czas działania algorytmu.

test\_times.append(timeit(search, number = 50000))

print(f"Czas dla wyszukania w części {j+1}.: {t}")
print("----")

print("\*\*\* Podane czasy odpowiadają 50000 wyszukiwań \*\*\*\n")

print(f"Wyniki po podziale pliku na {test} części")

print(f"Sumaryczny czas : {sum(times[i])}\n")